Relatório Prático: Redes Neurais Artificiais Clássicas no Conjunto Iris

1. Introdução e Contextualização

Este trabalho apresenta uma análise comparativa de três arquiteturas fundamentais de Redes Neurais Artificiais (RNAs): o **Perceptron de camada única**, o **ADALINE** e o **Multilayer Perceptron (MLP)**. Utilizou-se o dataset Iris, um padrão na literatura de aprendizagem de máquina, para avaliar como diferentes modelos lidam com a classificação de espécies vegetais a partir de atributos físicos. O foco reside na compreensão de como a complexidade da rede afeta a geometria das fronteiras de decisão e a precisão dos resultados.

2. Fundamentação Teórica dos Modelos

- **Perceptron (Camada Única):** É o modelo mais básico de neurônio artificial. Funciona como um classificador linear que ajusta os seus pesos apenas quando ocorre um erro de classificação. A sua saída é determinada por uma função degrau, o que o torna eficiente para problemas linearmente separáveis, mas incapaz de convergir em zonas de sobreposição de classes.
- **ADALINE (Adaptive Linear Neuron):** Embora também seja um modelo linear, o ADALINE introduz o uso de uma função de ativação linear durante o treino. A atualização dos pesos baseia-se na minimização do erro quadrático médio (MSE) através do Gradiente Descendente. Isto proporciona um treino mais estável que o Perceptron original.
- **MLP (Multilayer Perceptron):** Representa a evolução para redes não lineares. Ao incluir camadas ocultas e funções de ativação não lineares (como ReLU), o MLP consegue aprender padrões complexos e "curvar" as fronteiras de decisão, superando a limitação da separabilidade linear.

3. Metodologia Experimental

Para garantir a visualização e o rigor estatístico, adotaram-se as seguintes etapas:

1. **Seleção de Atributos:** Utilizaram-se apenas o comprimento e a largura da pétala (*petal length* e *petal width*) para permitir a representação gráfica em 2D.
2. **Pré-processamento:** Aplicou-se a padronização (*StandardScaler*) para que todos os atributos tivessem média zero e variância unitária, evitando que escalas diferentes distorcessem o treino.
3. **Protocolo de Teste:** Foram realizadas **30 execuções independentes** para cada modelo, com uma divisão de 80% para treino e 20% para teste, garantindo a fiabilidade dos resultados através da média e do desvio padrão.

4. Resultados Experimentais

Os resultados obtidos após as 30 rodadas foram os seguintes:

Modelo	Acurácia Média	Desvio Padrão
Perceptron	85.78%	0.0935
ADALINE	77.22%	0.0502
MLP	**96.11%**	**0.0311**

Matrizes de Confusão Acumuladas:

- **Perceptron:** Mostrou dificuldade na separação entre as classes 1 e 2, com erros significativos de dispersão.
- **ADALINE:** Embora estável, apresentou uma alta taxa de confusão (147 erros) entre a espécie *Versicolor* e a *Virginica*, evidenciando a falha do modelo linear em áreas de sobreposição.
- **MLP:** Demonstrou quase perfeição, com apenas 14 e 21 erros acumulados entre as classes mais complexas, validando a sua superioridade.

5. Visualização e Análise das Fronteiras de Decisão

*(Nesta secção, deve inserir a imagem **fronteiras_redes_neurais.png** gerada pelo seu código)*

A visualização gráfica confirma os dados numéricos:

- As fronteiras do **Perceptron** e do **ADALINE** são representadas por linhas retas. Como as espécies *Versicolor* e *Virginica* estão fisicamente próximas no dataset, uma linha reta é insuficiente para separá-las sem incluir elementos da classe errada.
- A fronteira do **MLP** apresenta uma forma mais adaptativa (não linear), conseguindo "contornar" os dados e criar uma zona de separação muito mais precisa entre as espécies.

6. Discussão Crítica Comparativa

Os resultados demonstram um aumento progressivo de desempenho conforme a arquitetura da rede se torna mais robusta. O **MLP** não só obteve a maior acurácia (96.11%), como foi o modelo mais estável (menor desvio padrão).
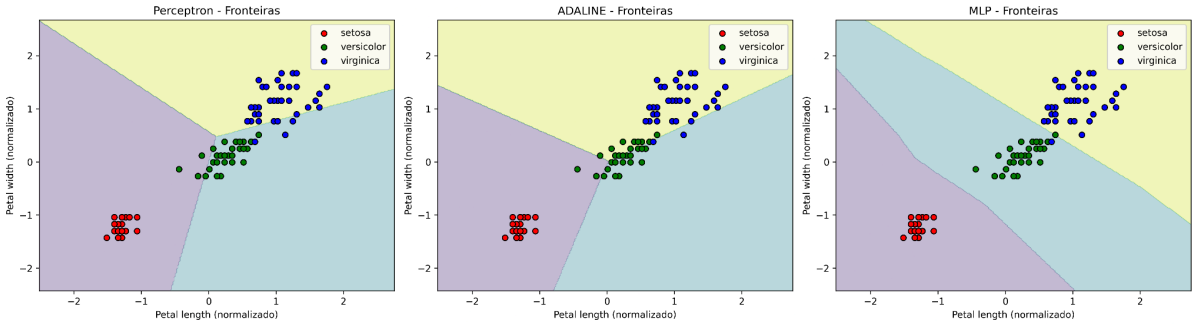
Conclui-se que para problemas simples e linearmente separáveis (como identificar a espécie *Setosa*), modelos básicos como o Perceptron são suficientes. No entanto, para a classificação completa do dataset Iris, onde existe sobreposição de características entre as espécies *Versicolor* e *Virginica*, a capacidade não linear do **MLP** é fundamental para garantir resultados de alta fiabilidade.